Université des Sciences et de la Technologie Houari Boumediene

Faculté d'Informatique

Département IA & SD

RAPPORT DE PROJET SYSTÈME DE PROGRAMMATION SCRIPT

Spécialité : BIOINFORMATIQUE

Thème

Quels gènes concentrent le plus de variants distincts classés « Pathogenic » ou « Likely pathogenic » dans ClinVar, associés spécifiquement à la cardiomyopathie hypertrophique ?

NOM ET PRENOM	MATRICULE
AGGOUN SOUNDOUS YASMINE	222231369119
DAOUDI ANFAL	232331601003
TOUBAL ABDELGHANI	212131068318
ZAOUAR MERIEM	222231355920
BELFERKOUS IMENE	212231693910

2026/2027

1. Question et contexte :

La cardiomyopathie hypertrophique (CMH) est la cardiopathie génétique la plus fréquente (prévalence estimée à 1/500). Elle se caractérise par une hypertrophie ventriculaire gauche non expliquée par une cause hémodynamique et peut conduire à l'insuffisance cardiaque ou à la mort subite chez l'adulte jeune. Transmise sur un mode autosomique dominant, elle est qualifiée de « maladie du sarcomère ». Nous interrogeons la base publique **NCBI ClinVar** pour identifier les gènes qui concentrent le plus de variants classés pathogènes ou probablement pathogènes.

Unité de mesure. Nous dénombrons des VariationID distincts par gène, et non des patients : il s'agit d'une mesure de l'hétérogénéité mutationnelle enregistrée dans ClinVar, pas d'une prévalence clinique.

2. Données :

Le jeu de données est le fichier variant_summary de ClinVar, archive mensuelle 2026-10, téléchargé le 04/11/2026 (domaine public, US Government Work). Nous utilisons l'archive datée plutôt que le fichier courant, afin que les résultats restent reproductibles.

- **Adresse :** ftp.ncbi.nlm.nih.gov/pub/clinvar/tab_delimited/archive/variant_summary_2026-10.txt.gz
- **Taille :** 450 727 547 octets compressés (≈ 430 Mio) ; 4 043 056 609 octets décompressés.
- **SHA-256 :** `a6a58df4d9049c9187a79a8fb4e70f1f3b5550e1708c6c74b7be0b268f5032da`

Le script run.sh télécharge le fichier, compare son empreinte SHA-256 à celle de config/dataset.env, teste l'archive (gzip -t), puis la verrouille en lecture seule (chmod a-w). Toute différence interrompt le pipeline.

3. Méthode et définition du motif :

Motif recherché : un enregistrement ClinVar est retenu s'il vérifie simultanément les cinq critères suivants.

1. Assembly = GRCh38 ; OriginSimple = germline.
2. Un élément de PhenotypeList est strictement égal à « Hypertrophic cardiomyopathy » ou « Hypertrophic cardiomyopathy N » (N = sous-type facultatif).
3. ClinicalSignificance ∈ {Pathogenic, Likely pathogenic, Pathogenic/Likely pathogenic}.
4. GeneSymbol renseigné et correspondant à un seul gène (symboles vides, « - », « NA » ou contenant « ; » exclus).
5. Un même VariationID n'est compté qu'une fois par gène.

Étape Shell (scripts/filter_hcm_variants.sh). Le fichier de 4 Go n'est jamais extrait sur le disque : un enchaînement de commandes par tubes (gzip -cd, awk, sort, uniq) lit le flux compressé, applique les critères 1 et 2 du motif et écrit data/processed/hcm_variants_grch38.tsv, soit 17 012 enregistrements.

Étape Python (scripts/analyze_genes.py, argparse). Elle applique les critères 3 à 5, classe les gènes et produit gene_ranking.csv, variants_hcm.csv, excluded_variants.csv (avec le motif d'exclusion de chaque ligne), summary.json et top_genes.png. Sur 17 012 enregistrements, 1 427 associations variant–gène sont retenues et 15 585 exclues (1 427 + 15 585 = 17 012).

4. Résultats :

Les 1 427 associations retenues se répartissent sur 40 gènes. Le tableau donne le Top 15 ; les pourcentages sont calculés sur les 1 427 associations retenues.

```
[2026-11-07 23:23:11] [INFO] Classement des 15 premiers genes (results/gene_ranking.csv)
Rank    GeneSymbol    DistinctVariantCount    PercentageOfRetainedVariants
1       MYBPC3        832                     58.3
2       MYH7          309                     21.65
3       FLNC          66                      4.63
4       TNNI3         56                      3.92
5       TNNT2         32                      2.24
6       TPM1          24                      1.68
7       TTN           14                      0.98
8       PRKAG2        11                      0.77
9       MYL2          10                      0.7
10      ALPK3         8                       0.56
11      MYH7B         8                       0.56
12      LAMP2         7                       0.49
13      MYH6          5                       0.35
14      ACTC1         4                       0.28
15      JPH2          4                       0.28
[2026-11-07 23:23:11] [OK] Pipeline termine avec succes.
```

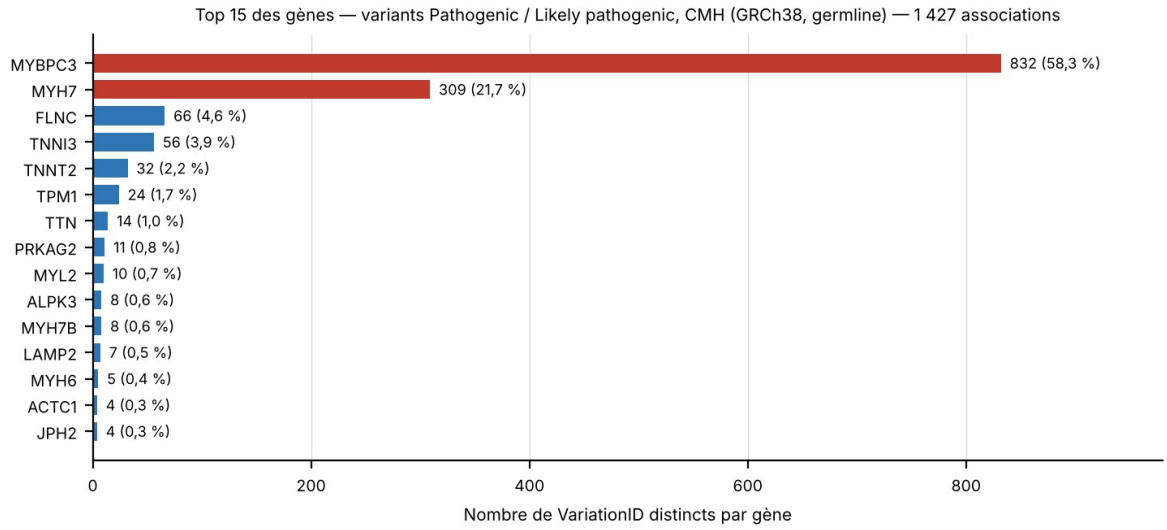


Figure 1 : variants distincts « Pathogenic » ou « Likely pathogenic » associés à la CMH (GRCh38, germline). MYBPC3 et MYH7 totalisent 1 141 des 1 427 associations (79,96 %).

5. Discussion

MYBPC3 et MYH7 dominent. MYBPC3 (58,30 %) et MYH7 (21,65 %) regroupent 79,96 % des associations retenues. Ce résultat est cohérent avec le rôle prédominant de ces deux gènes décrit dans la littérature (Marian & Braunwald, 2017), même si nous comptons des variants distincts et non des patients. MYBPC3 est marqué par de nombreux variants tronquants conduisant à une haplo-insuffisance ; MYH7 par des variants faux-sens situés surtout dans la tête motrice de la myosine, à effet dominant-négatif.

Filament fin. TNNI3, TNNT2, TPM1 et ACTC1 régulent l'interaction actine–myosine par le calcium ; TNNT2 et TNNI3 représentent à eux deux 88 associations (6,17 %).

Gènes hors sarcomère et phénocopies. FLNC (4,63 %, 3e rang) est associé à des cardiomyopathies arythmogènes. PRKAG2 (glycogénose cardiaque avec préexcitation) et LAMP2 (maladie de Danon, liée à l'X) rappellent l'importance du diagnostic différentiel : ce sont des phénocopies de la CMH. JPH2 et ACTC1 ferment le Top 15 à égalité (4 variants).

6. Limites

- ClinVar est une base participative : les gènes très présents dans les panels hospitaliers (MYBPC3, MYH7) y sont davantage soumis que des gènes récemment décrits comme ALPK3.
- Un variant récurrent chez 200 patients compte pour un seul VariationID, tout comme un variant familial unique : les résultats décrivent la diversité des allèles, pas la fréquence de la maladie.
- Un même VariationID peut être associé à plusieurs gènes ; les 1 427 sont donc des associations variant–gène et non des variants strictement uniques. Les enregistrements à classification incertaine, bénigne ou conflictuelle, ou à gène ambigu, sont exclus et tracés dans excluded_variants.csv.
- Le filtre de phénotype est volontairement strict ; il écarte les variants dont la CMH n'apparaît que dans une liste de phénotypes plus large.

7. Reproductibilité et administration système

Le pipeline s'exécute avec ./run.sh et le seul README.md. Il applique set -Eeuo pipefail, des fonctions réutilisées
(log, die, verify_file, download_file…), les options getopts -c, -t, -f, -n et -h, et un trap qui supprime les fichiers temporaires à la sortie ou à l'interruption. Chaque lancement écrit un journal horodaté dans logs/ et archive les résultats dans un fichier tar daté. L'environnement Python est isolé (venv + requirements.txt) ; une tâche cron mensuelle est fournie (cron/clinvar_pipeline.cron) ; des tests unittest valident le traitement (tests/). Le pipeline a été exécuté de bout en bout puis relancé sans nettoyage manuel.

8. Conclusion

Dans ClinVar (release 2026-10), la diversité des variants pathogènes ou probablement pathogènes associés à la CMH est très concentrée : MYBPC3 (832 variants) et MYH7 (309) représentent près de 80 % des 1 427 associations retenues sur 40 gènes. Le pipeline Shell/Python fournit ce résultat de façon automatique, vérifiable et reproductible.

Références :

1. Landrum MJ, et al. ClinVar: improvements to access, data extraction and curation. Nucleic Acids Res. 2020;48(D1):D835-D844.
2. Marian AJ, Braunwald E. Hypertrophic cardiomyopathy: genetics, pathogenesis, clinical manifestations, diagnostic evaluation, and prognosis. Circ Res. 2017;121(7):749-770.
3. Richards S, et al. Standards and guidelines for the interpretation of sequence variants (ACMG/AMP). Genet Med. 2015;17(5):405424.
4. Ommen SR, et al. 2020 AHA/ACC guideline for the diagnosis and treatment of patients with hypertrophic cardiomyopathy. Circulation. 2020;142(25):e533-e557.